گزارش نهایی پروژه

بازتولید منحنی بده‌بستان سرعت–کیفیت در تبدیل متن به گفتار

اثر تعداد گام‌های دیکدر (NFE) بر سرعت و کیفیت در مدل آماده Matcha-TTS،
با الهام از پرسش پژوهش DriftTTS: «با چند فراخوانی دیکدر، کیفیت حفظ می‌شود؟»

نام دانشجو	سدرا
نام استاد	.....
نام درس	.....
محیط اجرا	Google Colab با پردازنده گرافیکی Tesla T4
تاریخ	14 آبان 1405 (5 نوامبر 2026)

نتیجه در یک نگاه

NFE = 2
نقطه زانویی در سنجه دیواری (نتیجه موقت، نه قطعی)

6.65% → 2.83%
بهبود WER از NFE=1 به NFE=2؛ بعد از آن ثابت

RTF ≈ 0.40
RTF دیواری از NFE=2 تا 25 تقریبا ثابت و زیر 1 (سریع‌تر از زمان واقعی)

پیام اصلی گزارش: از NFE=2 به بعد نه کیفیت بهتر شد و نه زمان دیواری تغییر کرد؛ چون زمان بارگذاری مدل و وکودر اثر خود دیکدر را پنهان کرد. پس زانوییِ دیده‌شده، زانوییِ «سامانه کامل در سنجه دیواری» است، نه خود دیکدر (بخش 7).

فهرست مطالب

چکیده 2
1. مقدمه و پیشینه 2
2. پرسش پژوهش و فرضیه 2
3. روش اجرا 3
4. نتایج 4
5. تحلیل و تفسیر 6
6. محدودیت‌ها 6
7. کار آینده: اندازه‌گیری فقط دیکدر 7
8. نتیجه‌گیری 7
منابع 7
پیوست‌ها 8

چکیده

مدل‌های مدرن تبدیل متن به گفتار (TTS) که بر پایه انطباق جریان (Flow Matching) کار می‌کنند، برای ساختن مل‌اسپکتروگرام، دیکدر خود را چندین بار صدا می‌زنند. هر فراخوانی دیکدر یک گام حل معادله دیفرانسیل معمولی (ODE) است و تعداد این گام‌ها با NFE (تعداد ارزیابی‌های تابع) سنجیده می‌شود. پرسش عملی این است: اگر NFE را کم کنیم، چقدر سرعت می‌گیریم و چقدر کیفیت از دست می‌دهیم؟ این پروژه همان پرسش مقالات کم‌گام مانند DriftTTS را، بدون آموزش هیچ مدلی از صفر، روی مدل آماده Matcha-TTS بازتولید می‌کند. ده جمله ثابت انگلیسی (در مجموع 101 کلمه) با NFE برابر 1، 2، 4، 10 و 25 سنتز شدند؛ سرعت با RTF دیواری و کیفیت با نرخ خطای کلمه (WER) به کمک رونویسی faster-whisper نسخه tiny و یک بررسی شنیداری سنجیده شد. نتیجه: WER از 6.65 درصد در NFE=1 به 2.83 درصد در NFE=2 رسید و در NFEهای 4 و 10 همان ماند؛ RTF دیواری نیز از 0.518 به حدود 0.40 افت کرد و بعد ثابت ماند. پس زانوییِ منحنی در سنجه دیواری حدود NFE=2 است، اما موقت است؛ چون اثر واقعی دیکدر زیر زمان ثابت بارگذاری و وکودر پنهان مانده است.

واژگان کلیدی: تبدیل متن به گفتار، انطباق جریان، DriftTTS، Matcha-TTS، تعداد ارزیابی تابع (NFE)، عامل زمان واقعی (RTF)، نرخ خطای کلمه (WER).

1. مقدمه و پیشینه

در TTS عصبی، متن ابتدا به مل‌اسپکتروگرام تبدیل می‌شود و سپس وکودر آن را به موج صدا برمی‌گرداند. مدل Matcha-TTS (مهتا و همکاران، ICASSP 2024) یک مدل آکوستیک انکودر–دیکدر است که با «انطباق جریان شرطی با انتقال بهینه» (OT-CFM) آموزش دیده است؛ دیکدر آن یک حل‌کننده ODE است که از نویز شروع می‌کند و در چند گام به مل‌اسپکتروگرام می‌رسد. مزیت این خانواده رسیدن به کیفیت خوب با گام کمتر از مدل‌های مبتنی بر تطبیق امتیاز است، اما پرسش باقی می‌ماند: «کمتر» یعنی چقدر؟

مقاله DriftTTS (آن، کیم و کیم، 2026) همین پرسش را از سمت آموزش جواب می‌دهد: با هدف آموزشی «رانش مولد» (Generative Drifting) و نسخه قطعه‌ای آن برای گفتار با طول متغیر، مدلی می‌سازد که فقط با **یک** فراخوانی دیکدر، به کیفیت چندگامی Matcha-TTS و RapFlow-TTS روی LJSpeech می‌رسد و سریع‌تر است؛ راه معمول کم‌کردن گام‌ها تقطیر از یک معلم چندگامی است و DriftTTS نشان می‌دهد بدون آن هم می‌شود.

این پروژه راه دیگری می‌رود: به‌جای آموزش مدل تازه، منحنی بده‌بستان سرعت–کیفیتِ یک مدل آماده (Matcha-TTS به همراه وکودر HiFi-GAN) را با تغییر NFE اندازه می‌گیرد؛ یعنی پرسش DriftTTS از زاویه «استنتاج» بررسی می‌شود: اگر مدل آماده با گام کمتر کار کند، منحنی کیفیتش چه شکلی می‌شود و زانویی کجاست؟

2. پرسش پژوهش و فرضیه

پرسش: با کم‌کردن NFE در Matcha-TTS آماده، سرعت و کیفیت چگونه تغییر می‌کند و نقطه زانویی کجاست؟

فرضیه‌ها:

- کیفیت (WER) با افزایش NFE ابتدا سریع بهتر می‌شود و بعد اشباع می‌شود؛ افت اصلی کیفیت در NFE=1 دیده می‌شود.
- زمان خود دیکدر باید تقریبا با NFE رشد کند؛ اما اگر زمان بارگذاری مدل و وکودر بزرگ باشد، در سنجه دیواری دیده نمی‌شود و منحنی RTF تخت می‌ماند.
- بررسی شنیداری باید با WER هم‌جهت باشد: صدای NFE=1 باید به گوش هم خراب‌تر از NFE=10 شنیده شود.

3. روش اجرا

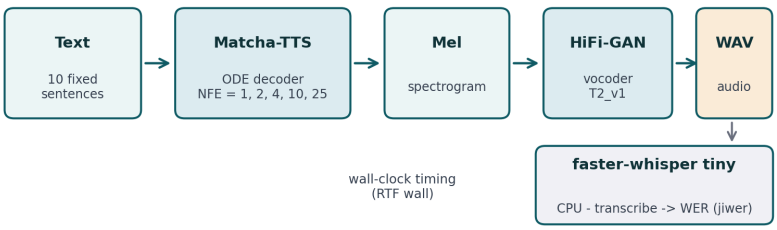
3.1 محیط و ابزارها

آزمایش در Google Colab روی Tesla T4 اجرا شد. نصب مستقیم Matcha-TTS روی پایتون پیش‌فرض Colab (3.13) ممکن نبود، چون Matcha به numpy نسخه 1 نیاز دارد و روی پایتون 3.13 بسته آماده‌ای برای آن نیست؛ راه حل، محیط جدا پایتون 3.11 با ابزار uv بود (matcha311) که numpy 1.26.4 در آن آماده نصب شد. همچنین بارگذاری پیش‌فرض فقط‌وزن (weights_only=True) چک‌پوینت رسمی Matcha را رد می‌کند؛ چون این چک‌پوینت از انتشار رسمی Matcha دانلود می‌شود، گزینه weights_only=False فقط برای همین فایل فعال شد و برای فایل‌های ناشناس نباید به کار رود.

جزء	مشخصات این آزمایش
سخت‌افزار	Google Colab، پردازنده گرافیکی Tesla T4، CUDA: True
محیط نرم‌افزاری	پایتون 3.11 (محیط مجازی uv با نام matcha311)، torch 2.15.0+cu132، numpy 1.26.4
مدل آکوستیک	matcha_ljspeech (تک‌گوینده، از پیش آموزش‌دیده روی LJSpeech)
وکودر	hifigan_T2_v1
تنظیمات ثابت سنتز	دما 0.667 و نرخ گفتار 0.95 (پیش‌فرض Matcha) در همه NFEها ثابت
رونویسی برای WER	faster-whisper مدل tiny روی CPU با compute_type=int8 و محاسبه WER با jiwer

رونویسی روی CPU اجرا شد، چون نسخه GPU کتابخانه libcublas.so.12 را در محیط پیدا نمی‌کرد؛ مدل tiny برای 50 فایل کافی بود.

3.2 خط لوله آزمایش



شکل 1. خط لوله آزمایش: سنتز در پنج مقدار NFE، وکودر، و ارزیابی با زمان‌گیری دیواری و رونویسی.

3.3 جمله‌های ثابت و پروتکل اندازه‌گیری

هر پنج مقدار NFE روی دقیقا همان 10 جمله (پیوست الف) اجرا شدند؛ جمله‌ها ساده و بدون عدد و مخففاند تا خطای WER تا حد ممکن از خود مدل باشد، نه از متن. برای هر NFE، مدل یک بار بارگذاری شد و 10 جمله به‌صورت دسته‌ای تولید شدند (در مجموع 50 فایل صوتی). پیش از آن، سلامت زنجیره در مرحله 1 با یک جمله آزمایشی (NFE=10) تایید شد.

RTF دیواری: زمان کل سنتز (با بارگذاری مدل و وکودر) تقسیم بر مجموع مدت صداها؛ زیر 1 یعنی سریع‌تر از زمان واقعی. **WER:** رونویسی با faster-whisper tiny و نرخ خطای کلمه با jiwer، میانگین روی 10 جمله. **بررسی شنیداری:** جمله 3 در NFEهای 1، 10 و 25.

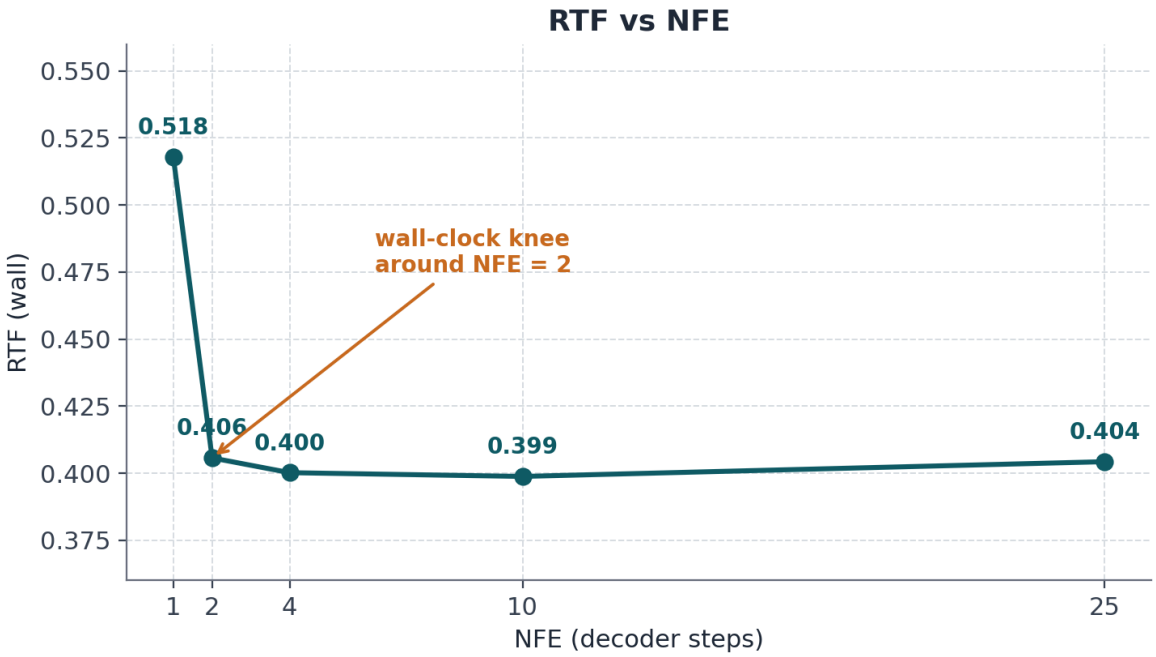
4. نتایج

جدول 1 خروجی کامل مرحله 2 است؛ همان مقادیری که در فایل summary.csv آزمایش ثبت شد. مجموع مدت صدا در هر پنج NFE برابر 35.86 ثانیه است، چون جمله‌ها و نرخ گفتار در همه اجراها ثابت بودند؛ پس تفاوت زمان دیواری فقط از مسیر اجرا می‌آید، نه از طول خروجی.

Total duration (s)	Wall time (s)	Mean WER	RTF (wall)	NFE
35.86	18.6	0.0665 (6.65%)	0.5180	1
35.86	14.5	0.0283 (2.83%)	0.4057	2
35.86	14.4	0.0283 (2.83%)	0.4002	4
35.86	14.3	0.0283 (2.83%)	0.3988	10
35.86	14.5	0.0483 (4.83%)	0.4043	25

جدول 1. نتایج مرحله 2 برای 10 جمله ثابت. WER میانگین روی 10 جمله و با faster-whisper tiny محاسبه شده است.

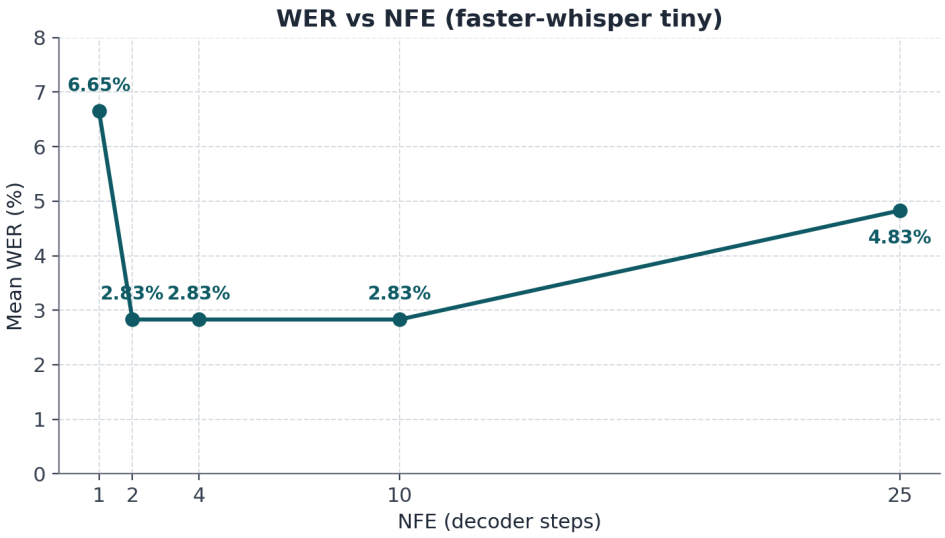
4.1 سرعت: RTF دیواری در برابر NFE



شکل 2. RTF دیواری در برابر NFE. تنها افت محسوس بین NFE=1 و 2 است؛ از 2 تا 25 منحنی عملا تخت است.

RTF در NFE=1 برابر 0.518 است و در NFE=2 به 0.4057 می‌رسد؛ یعنی زمان دیواری حدود 22 درصد کم می‌شود (از 18.6 به 14.5 ثانیه). اما از NFE=2 تا 25، RTF فقط در بازه باریک 0.3988 تا 0.4057 نوسان می‌کند و زمان دیواری بین 14.3 تا 14.5 ثانیه می‌ماند. به بیان دیگر، در این سنجه، 25 گام دیکدر از 2 گام کندتر نیست. همه مقادیر RTF زیر 1 هستند؛ یعنی کل سامانه، حتی با احتساب بارگذاری، سریع‌تر از زمان واقعی کار کرده است.

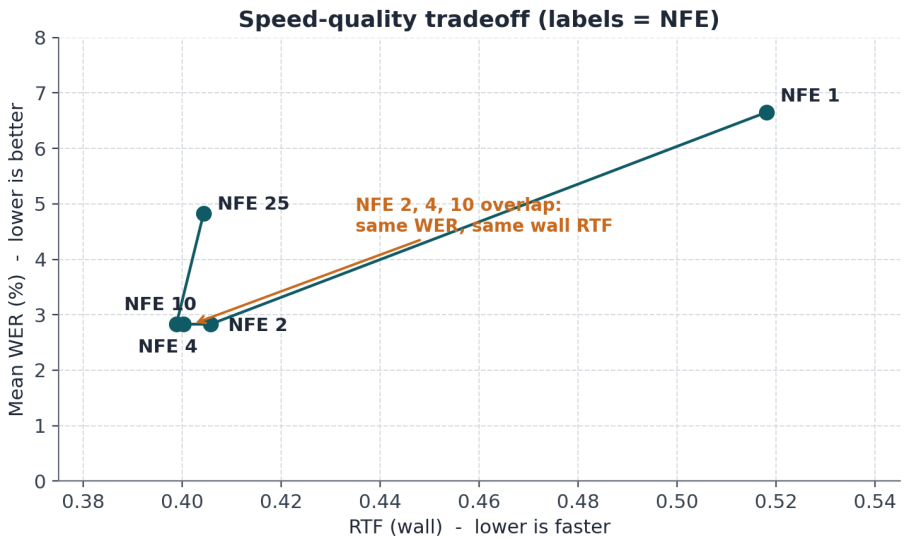
4.2 کیفیت: WER در برابر NFE



شکل 3. میانگین WER در برابر NFE. افت اصلی بین 1 و 2 رخ می‌دهد؛ مقادیر 2، 4 و 10 یکسان‌اند.

WER در NFE=1 برابر 6.65 درصد است؛ در NFE=2 به 2.83 درصد می‌رسد (کاهش 3.82 واحد درصدی، یعنی حدود 57 درصد بهبود نسبی) و در NFEهای 4 و 10 دقیقا همان 2.83 درصد می‌ماند. پس اشباع کیفیت در این آزمایش از همان NFE=2 شروع می‌شود. مقدار NFE=25 با 4.83 درصد کمی بدتر شده است؛ تفسیر این برگشت در بخش 5 می‌آید و آن را بهبود یا افت واقعی کیفیت نمی‌دانیم.

4.3 منحنی بده‌بستان و بررسی شنیداری



شکل 4. بده‌بستان سرعت–کیفیت؛ هر نقطه یک NFE است. نقطه NFE=1 جدا و بالا-راست افتاده و نقطه‌های 2، 4 و 10 روی هم جمع شده‌اند.

در نمودار بده‌بستان، فقط دو ناحیه از هم جدا می‌شوند: NFE=1 (کندتر و بدتر) و خوشه NFEهای 2 تا 10 (سریع‌تر و بهتر). NFE=25 در همان خوشه سرعت می‌نشیند ولی WERش بالاتر است. بررسی شنیداری جمله 3 نیز با اعداد هم‌خوان بود: صدای NFE=1 در برابر NFE=10 به گوش خراب‌تر شنیده شد. پس هر سه فرضیه بخش 2 از نظر جهت، با داده سازگارند؛ داوری دقیق‌تر در بخش بعد می‌آید.

5. تحلیل و تفسیر

زانویی کجاست؟ در سنجه دیواری و با همین 10 جمله، زانویی حدود NFE=2 است: گذر از 1 به 2 هم‌زمان RTF را حدود 22 درصد و WER را از 6.65 به 2.83 درصد بهبود می‌دهد، و بعد از 2 هیچ‌کدام از دو سنجه دیگر بهتر نمی‌شود. اما این حکم فقط درباره «سامانه کامل در سنجه دیواری» است، نه درباره خود دیکدر؛ به دلیل زیر، آن را نتیجه موقت می‌دانیم.

چرا زمان بعد از NFE=2 تخت ماند؟ زمان دیواری هر اجرا از سه بخش ساخته می‌شود: بارگذاری مدل و وکودر، کار دیکدر (که باید با NFE رشد کند) و خود وکودر. وقتی زمان کل از NFE=2 تا 25 فقط 0.2 ثانیه نوسان می‌کند، یعنی سهم دیکدر از زمان کل آن‌قدر کوچک است که رشدش زیر سهم ثابت بارگذاری و وکودر گم می‌شود. این دقیقا همان چیزی است که فرضیه دوم پیش‌بینی می‌کرد. یک شاهد دیگر: NFE=1 با وجود کمترین کار دیکدر، *بیشترین* زمان دیواری را دارد (18.6 ثانیه)؛ چنین برگشتی با زمان دیکدر توضیح داده نمی‌شود و بیشتر به نوسان اجرای اول (گرم‌شدن و کش) می‌خورد. پس از این جدول نمی‌شود سرعت واقعی دیکدر را در هر NFE خواند.

چرا WER در NFE=25 بدتر شد؟ این را افت واقعی کیفیت نمی‌دانیم. کل داده فقط 101 کلمه در 10 جمله است و WER میانگین جمله‌ای است؛ در این مقیاس، اختلاف 2 واحد درصدی می‌تواند از خطای رونویسی در یک یا دو جمله بیاید. از طرف دیگر، خود رونویس هم مدل tiny است که خطای خودش را به WER اضافه می‌کند و در همه NFEها یکسان نیست، چون صداها متفاوت‌اند. سنتز هم با دمای ثابت 0.667 تصادفی است و هر NFE فقط یک بار اجرا شده است. پس برای داوری درباره 25 در برابر 10، تکرار و داده بیشتر لازم است؛ چیزی که داده فعلی با اطمینان می‌گوید فقط برتری 2 تا 10 بر 1 است.

رابطه با DriftTTS: جهت کلی نتیجه با ادعای DriftTTS سازگار است: در NFEهای خیلی کم هم می‌شود به کیفیت قابل قبول رسید و گام بیشتر همیشه کیفیت بهتر نمی‌آورد. ولی آزمایش ما ادعای اصلی آن مقاله را ثابت نمی‌کند؛ چون اولا مدل ما Matcha آماده است نه مدل آموزش‌دیده با رانش، و ثانیا سنجه سرعت ما دیواری است. آنچه این پروژه نشان می‌دهد صورت استنتاجی همان ایده است: برای این مدل و این مقیاس، منحنی کیفیت زود اشباع می‌شود.

6. محدودیت‌ها

محدودیت	اثر بر نتیجه	راه کاهش در ادامه
RTF دیواری است و بارگذاری مدل و وکودر را شامل می‌شود	اثر NFE بر زمان دیکدر پنهان می‌ماند؛ عدد مطلق با RTF مقالات قابل مقایسه نیست	اندازه‌گیری فقط دیکدر (بخش 7)
WER با Whisper tiny سنجیده شده	عدد مطلق WER از مقالات با مدل بزرگ بالاتر است؛ نویز رونویسی وارد مقایسه می‌شود	تکرار با مدل بزرگ‌تر Whisper و گزارش بازه اطمینان
فقط 10 جمله، یک گوینده انگلیسی (LJSpeech)	تعمیم به فارسی، گوینده‌های دیگر یا جمله‌های بلند مجاز نیست	جمله بیشتر و متنوع‌تر؛ گوینده‌های VCTK
هر NFE فقط یک اجرا، با دمای ثابت 0.667	پراکندگی تصادفی سنتز سنجیده نشده؛ اختلاف‌های کوچک (مثل 25 در برابر 10) قابل داوری نیست	چند تکرار برای هر NFE و گزارش میانه
بررسی شنیداری فقط جمله 3 و بدون امتیازدهی رسمی	شاهد کیفی است، نه سنجه MOS؛ برای مقایسه دقیق کافی نیست	آزمون شنیداری کور با چند جمله و چند شنونده

7. کار آینده: اندازه‌گیری فقط دیکدر

قدم بعدی پروژه مشخص است: جدا کردن زمان دیکدر از زمان بارگذاری و وکودر تا زانویی واقعی دیده شود. پروتکل پیشنهادی:

1. مدل Matcha و وکودر فقط یک بار بارگذاری شوند و در حافظه بمانند؛ بارگذاری بیرون از زمان‌گیری است.
2. پیش از اندازه‌گیری، چند سنتز گرم‌کردن (Warm-up) اجرا و دور ریخته شود تا اثر اجرای اول حذف شود.
3. زمان فقط پیرامون حلقه حل ODE دیکدر گرفته شود، بدون وکودر؛ برای دقت روی GPU از torch.cuda.Event با همگام‌سازی استفاده شود، نه ساعت دیواری.
4. برای هر NFE دست‌کم 5 تکرار اجرا و میانه و دامنه بین‌چارکی (IQR) گزارش شود.
5. خروجی نهایی: جدول و منحنی RTF فقط‌دیکدر در برابر NFE، کنار WER فعلی؛ زانویی قطعی از همین منحنی خوانده می‌شود.

افزون بر آن، دو گسترش طبیعی وجود دارد: تکرار WER با مدل بزرگ‌تر Whisper برای کم‌کردن نویز رونویسی، و افزودن جمله‌های بیشتر و یک آزمون شنیداری کور کوچک به‌جای شنیدن تک‌جمله‌ای.

8. نتیجه‌گیری

در این پروژه، منحنی بده‌بستان سرعت–کیفیت Matcha-TTS آماده روی 10 جمله ثابت و پنج مقدار NFE بازتولید شد. کیفیت از NFE=1 به 2 به‌روشنی بهتر شد (WER از 6.65 به 2.83 درصد) و بعد اشباع شد؛ شنیدن نیز همین را تایید کرد. سرعت دیواری از NFE=2 به بعد ثابت ماند، چون زمان بارگذاری و وکودر بر زمان کل چیره بود. پس پاسخ آزمایش به پرسش پژوهش دو بخش دارد: زانوییِ سامانه کامل در سنجه دیواری حدود NFE=2 است، اما زانوییِ خود دیکدر با این روش قابل تعیین نیست و به اندازه‌گیری فقط‌دیکدر (بخش 7) موکول می‌شود. همین تفکیک، مهم‌ترین درس روش‌شناختی پروژه است: در سامانه‌های چندبخشی، سنجه کلی می‌تواند اثر بخشی را که می‌خواهیم بسنجیم پنهان کند.

منابع

1. Ahn, J., Kim, D., & Kim, H. (2026). DriftTTS: One-stage Single Step Text-to-Speech via Generative Drifting. arXiv:2610.22960.
2. Mehta, S., Tu, R., Beskow, J., Székely, É., & Henter, G. E. (2024). Matcha-TTS: A Fast TTS Architecture with Conditional Flow Matching. Proc. ICASSP 2024, pp. 11341-11345. arXiv:2309.03199.
3. Kong, J., Kim, J., & Bae, J. (2020). HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis. Proc. NeurIPS 2020. (وکودر HiFi-GAN)
4. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision (Whisper). Proc. ICML 2023. (مبنای faster-whisper)
5. Matcha-TTS official implementation and pretrained checkpoints, github.com/shivammehta25/Matcha-TTS.

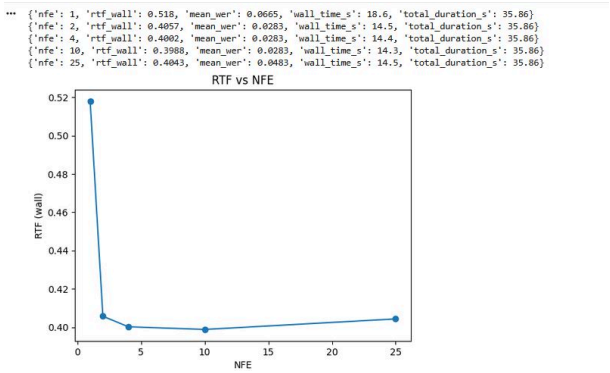
پیوست‌ها

پیوست الف. ده جمله ثابت آزمایش (مجموعا 101 کلمه)

#	Sentence
1	The quick brown fox jumps over the lazy dog.
2	She opened the window and looked at the garden.
3	The train arrived at the station just after sunset.
4	He read the book slowly, one page at a time.
5	The children played in the park until it started to rain.
6	A small bird sang on the branch above the quiet river.
7	The old house stood at the end of a long, dusty road.
8	She wrote a letter to her friend about the summer holiday.
9	The baker made fresh bread every morning before sunrise.
10	They walked home together under a sky full of stars.

پیوست ب. خروجی خام سلول نهایی نوت‌بوک در Colab

تصویر زیر خروجی اصلی اجرای مرحله 2 در Colab است؛ اعداد جدول 1 این گزارش عینا از همین خروجی گرفته شده‌اند.



شکل 5. خروجی خام Colab در مرحله 2 (تصویر ارسالی از محیط اجرا).

پیوست ج. چک‌لیست بازتولید

- در Colab، نوع Runtime را روی GPU (Tesla T4) بگذارید.
- محیط پایتون 3.11 را با uv بسازید (matcha311)؛ نصب روی پایتون 3.13 به numpy نسخه 1 نمی‌رسد.
- با uv pip install --python /content/matcha311/bin/python بسته‌های torch و matcha-tts را نصب کنید (محیط uv به‌صورت پیش‌فرض pip ندارد).
- فقط برای چک‌پوینت رسمی Matcha، وصله weights_only=False را در تابع load_matcha فایل matcha/cli.py اعمال کنید.
- جمله‌های پیوست الف را با NFEهای 1، 2، 4، 10 و 25 به‌صورت دسته‌ای سنتز کنید؛ برای هر NFE زمان دیواری را ثبت کنید.
- رونویسی را با faster-whisper tiny روی CPU (int8) انجام دهید و WER را با jiwer بگیرید؛ خروجی مورد انتظار: فایل summary.csv و سه نمودار بخش 4.